



Trabajo Práctico N.º 1

Un primer encuentro con la EPH

Grupo 5

Santiago Caballero Yver
Oriana Valentina Gegena
Valeria Eliana Gonzalez

Lunes 6 de julio de 2026

Link al repositorio de GitHub:

<https://github.com/santiagocaballeroiver/BigDataUBA-Grupo5>

Definición de informalidad asignada: Informal self-employed (grupo 5)



Parte I: Familiarizándonos con la base EPH y limpieza

Informalidad según INDEC.

El Instituto Nacional de Estadística y Censos (INDEC) define a la informalidad laboral como el conjunto de trabajadores asalariados e independientes que trabajan en unidades productivas al margen de la ley, es decir, no regulados. El INDEC analiza la condición de informalidad a través de tres categorías distintas: asalariados informales dependientes, que son aquellos que carecen de protección legal y se identifican en la EPH por falta de aportes regulatorios; luego están los trabajadores independientes informales (cuentapropistas o patrones) que son aquellos que incumplen las obligaciones tributarias y previsionales, y en la encuesta se pueden identificar al cruzar las variables de categoría ocupacional con el sector al que pertenece la empresa. Por último, se encuentran los trabajadores familiares sin remuneración a quienes el instituto categoriza automáticamente como informales.


Armonización de variables y limpieza de datos.

Con el objetivo de evaluar la calidad de la información para el análisis, elaboramos un mapa de calor (heatmap) que resume la proporción de valores faltantes (NaN) en las principales variables de estudio para la submuestra de ocupados de 15 años o más correspondiente al cuarto trimestre de 2024 y al cuarto trimestre de 2025. Previamente, se corrigieron los códigos especiales de no respuesta y se transformaron en valores faltantes para su adecuado tratamiento. La selección de la muestra se realizó a partir de la variable ESTADO (condición de actividad). En una primera etapa se conservaron únicamente los individuos que respondieron la pregunta sobre condición de actividad (ESTADO $\neq$ 0). Luego, dentro de este grupo se seleccionaron exclusivamente los ocupados (ESTADO = 1), obteniéndose una muestra final de 21.130 observaciones para el cuarto trimestre de 2024 y 19.689 observaciones para el cuarto trimestre de 2025.

Los resultados muestran una elevada respuesta en la mayoría de las variables sociodemográficas y laborales utilizadas. Variables como sexo, edad, nivel educativo, estado civil, categoría ocupacional y condición de actividad presentan porcentajes de valores faltantes prácticamente nulos en ambos períodos. Las mayores proporciones de datos faltantes se concentran en las variables de ingresos y jubilación. En particular, el ingreso total individual (P47T) registra niveles de no respuesta cercanos al 24%, mientras que el ingreso de la ocupación principal (P21) presenta porcentajes próximos al 23% en ambos años. También, la variable asociada a jubilación (PP07H) exhibe la mayor proporción de faltantes, con valores del 27,6% en 2024 y 29,2% en 2025. Por su parte, el tamaño de la empresa (PP04C) muestra niveles moderados de faltantes, cercanos al 13%.

Finalmente, de las variables centrales para la caracterización laboral de los ocupados, como las horas trabajadas (PP3E_TOT) y el sector laboral (SECTOR), se presentan porcentajes reducidos de valores faltantes, inferiores al 5%, lo que garantiza una adecuada cobertura de la información necesaria para los análisis posteriores. La similitud observada entre ambos períodos nos permite pensar una estructura de no respuesta estable entre ambos periodos.

Gráfico 1. Porcentaje de valores faltantes para cada variable interés.



Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025)

También construimos variables binarias con etiquetas interpretables para facilitar el análisis gráfico: Género (1 = Mujer, 0 = Varón, a partir de CH04), Cobertura (1 = posee algún tipo de cobertura de salud, 0 = no posee, a partir de CH08) y una variable categórica de tamaño de empresa (tam_micro, tam_pequena, tam_mediana, tam_grande) construida a partir de la cantidad de personas que trabajan en el establecimiento (PP04C).

Finalmente, para armonizar los ingresos de la ocupación principal (P21) y totales (P47T) de 2024 se actualizaron aplicando el coeficiente de inflación acumulada entre ambos trimestres (31,5%), de modo de expresar ambos años en pesos constantes de 2025T4 y garantizar la comparabilidad de los montos.

Parte II: Primer Análisis Exploratorio


Matriz de correlación para ambos periodos

Se construyó la matriz de correlación con las variables SECTOR, ESTADO, CAT_OCUP, P21, P47T, NIVEL_ED, CH04, CH06, CH07 y CH08 para cada año, utilizando *seaborn.heatmap()*.

Al comparar ambos períodos observamos una notable estabilidad estructural en las relaciones entre las variables socioeconómicas. La correlación entre el ingreso principal y el ingreso total se mantiene extremadamente alta y consistente, pasando de 0,93 en 2024 a 0,92 en 2025, lo que valida la coherencia interna de los datos. Asimismo, persiste una correlación positiva moderada entre el nivel educativo y los ingresos (entre 0,32 y 0,36), y se mantiene firme la relación negativa

entre el sector laboral y los ingresos (entre -0,40 y -0,45), así como la correlación inversa entre edad y estado civil (~-0,33), lo que evidencia que las dinámicas subyacentes capturadas por la EPH presentan una persistencia marcada entre ambos años.

Gráfico 2: Matriz de correlación para ambos trimestres



Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025)

Estadística descriptiva

Elaboramos las tablas estadísticas de las variables del estudio para reflejar la estructura sociodemográfica y laboral de la población bajo análisis. En la misma se reportan los números de observaciones, promedio, desvío estándar, mínimo, percentiles 1, 25, 50, 75 y 99, y máximo, para 2024T4 y 2025T4. Se aplicó también el *trimming* del 1% superior en los ingresos para controlar efectos de *outliers* realizado anteriormente.

Tabla 1: Resumen estadístico EPH - Cuarto Trimestre 2024:

	Obs.	Media	Desvío	Mín.	1%	25%	50%	75%	99%	Máx
Sector Laboral	20,273	1.38	0.61	1	1	1	1	2	3	3
Est. Ocupacional	37,839	1.85	0.97	1	1	1	1	3	3	3
Ocupación	22,074	2.7	0.54	1	1	2	3	3	3	4
Ingreso principal	16,329	\$615,856.02	\$484,813.16	\$2,000	\$30,560	\$280,000	\$500,000	\$800,000	\$2,500,000	\$3,000,000
Ingreso total	24,510	\$588,927.78	\$469,695.41	\$1,000	\$24,000	\$300,000	\$450,000	\$800,000	\$2,400,000	\$3,000,000
Educación	37,889	3.91	1.44	1	1	3	4	5	6	7
Sexo	37,889	1.53	0.5	1	1	1	2	2	2	2
Edad	37,889	43.59	19	15	15	27	42	58	86	103
Estado Civil	37,888	3.17	1.65	1	1	2	3	5	5	5
Cobertura Médica	37,851	2.07	1.89	1	1	1	1	4	12	123

Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025)

Tabla 2: Resumen estadístico EPH - Cuarto Trimestre 2025:

	Obs.	Media	Desvío	Mín.	1%	25%	50%	75%	99%	Máx
Sector Laboral	18,939	1.39	0.62	1	1	1	1	2	3	3



Est. Ocupacional	35,725	1.86	0.97	1	1	1	1	3	3	3
Ocupación	20,663	2.68	0.54	1	1	2	3	3	3	4
Ingreso principal	15,290	\$889,117.45	\$657,502.34	\$3,000	\$50,000	\$400,000	\$800,000	\$1,200,000	\$3,105,500	\$4,000,000
Ingreso total	22,980	\$838,020.19	\$648,765.95	\$700	\$30,000	\$390,000	\$671,400	\$1,095,000	\$3,152,100	\$4,000,000
Educación	35,784	3.89	1.44	1	1	3	4	5	6	7
Sexo	35,784	1.53	0.5	1	1	1	2	2	2	2
Edad	35,784	44.11	19.24	15	15	28	42	59	87	101
Estado Civil	35,781	3.18	1.65	1	1	2	3	5	5	5
Cobertura Médica	35,693	2.08	1.76	1	1	1	1	4	12	23

Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025)

Al comparar ambos trimestres se observa una notable consistencia en la estructura sociodemográfica de la muestra: variables como educación (media $\approx 3,9$), edad (media ≈ 44 años) y sexo se mantienen prácticamente invariables. En contraste, se evidencia un incremento nominal significativo en los ingresos, con el ingreso principal promedio pasando de 615.856 a 889.117 y el ingreso total de 588.927 a 838.020, comportamiento alineado con la dinámica inflacionaria del período, además observamos la existencia de la típica asimetría positiva de las distribuciones de ingresos, empujado por las observaciones de ingresos más altos concentradas en el último percentil de la muestra. Esta evolución en los valores monetarios, frente a la estabilidad de los indicadores poblacionales, sugiere que la depuración de *outliers* aplicada permitió capturar adecuadamente los ajustes nominales manteniendo la representatividad estadística de la muestra

Parte III: Conociendo la informalidad laboral

Análisis de Informalidad y creación del indicador


Siguiendo la definición de Maurizio & Monsalvo (2021), a nuestro grupo se le fue asignó la categoría *Informal self-employed*, correspondiente a trabajadores por cuenta propia no profesionales y trabajadores familiares sin remuneración que se desempeñan en el sector informal. Para la construcción del indicador utilizamos dos variables: CAT_OCUP (categoría ocupacional), de la cual seleccionamos los valores 2 (cuenta propia) y 4 (trabajador familiar sin remuneración), y SECTOR, que clasifica a cada ocupado en sector formal (1) o informal (2). Se clasificó como *Informal self-employed* a quienes son cuentapropistas que trabajan en el sector informal (CAT_OCUP = 2 y SECTOR = 2) o son trabajadores familiares sin remuneración (CAT_OCUP = 4). Los casos con valores faltantes en CAT_OCUP o SECTOR fueron excluidos del análisis.

Tabla 3. Incidencia de independientes informales por sexo

		Independientes Informales (%)	Resto de ocupados (%)	N observaciones
2024T4	Total	16.5	83.5	20273
	Mujeres	15	85	9244
	Varones	17.8	82.2	11029
2025T4	Total	17.5	82.5	18939
	Mujeres	16.4	83.6	8728
	Varones	18.5	81.5	10211

Gráfico 3: Ingreso de trabajadores informales

Los trabajadores informales por cuenta propia perciben ingresos sistemáticamente menores
EPH 2024T4 y 2025T4 (pesos a precios 2025T4)



Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025)

Los gráficos muestran que los trabajadores informales por cuenta propia perciben ingresos sistemáticamente menores que el resto de los ocupados. En ambos años y para ambas variables de ingreso, la distribución del grupo informal se concentra en los tramos bajos, con una cola derecha más corta, lo que indica que son pocos los trabajadores informales que alcanzan ingresos elevados. Respecto de las limitaciones de las variables utilizadas, P21 captura únicamente el ingreso de la ocupación principal, por lo que subestima el ingreso real de quienes tienen más de un trabajo, situación habitual entre los trabajadores informales. P47T, por su parte, incluye ingresos no laborales (jubilaciones, transferencias, programas sociales), lo que puede distorsionar la comparación entre grupos al no reflejar exclusivamente lo generado por la actividad laboral. A esto se suma que la tasa de no respuesta en ambas variables es mayor entre los informales, lo que introduce un sesgo adicional en el análisis.

Parte IV: Herramientas de IA y reflexión final

A lo largo del trabajo, la inteligencia artificial (principalmente ChatGPT y, en segundo lugar, Claude) resultó especialmente útil en el armado del código, dado que el grupo no cuenta con una amplia experiencia en programación con Python. La IA permitió eficientizar el tiempo de trabajo en la etapa de codeo, tanto agilizando el proceso de escritura del código como explicando los motivos de los distintos errores que fueron surgiendo, además de ayudar a lograr una visualización y presentación de gráficos y tablas clara y prolija. En cambio, resultó menos efectiva en la interpretación y el análisis de los resultados, ya que en general se limita a un análisis descriptivo superficial de las cifras.



Estimamos un tiempo total de aproximadamente 6 horas para la realización de este trabajo práctico.

Apéndice

A continuación, se listan, en el orden en que fueron utilizados, los prompts de inteligencia artificial empleados a lo largo del trabajo práctico, junto con la LLM utilizada en cada caso.

Prompt — Punto 2.b (ChatGPT)

"Hace un summary con los valores máximos, mínimos y cuartiles de las variables de interés. Quiero que los NS/NC los reemplaces por NaN."

Prompt – Punto 2.3 (ChatGPT)

Necesito solucionar el siguiente error: "NameError Traceback (most recent call last)Cell In[1], line 2 1 #Creamos la variable mujer: 0 Varón, 1 Mujer----> 2 ocupados['mujer'] = np.where(ocupados['CH04'] == 2, 1, 0) 4 #Variable Cobertura toma 1 si tiene algún tipo de cobertura y 0 si no. 5 condiciones_ch08 = [6 ocupados['CH08'].isin([1, 2, 3, 12, 13, 23, 123]), # Sí tiene cobertura 7 ocupados['CH08'] == 4 # No tiene cobertura 8]NameError: name 'np' is not defined"

Prompt – Punto 2.3 (ChatGPT)

"Para el siguiente grafico necesito sacar las variables dummies creadas y ordenar la información de mayor a menor"

Prompt – Punto 2.5 (ChatGPT)

"Necesito crear variables categóricas, pero lo quiero hacer agrupadas no una por una, usando la variable PP04C de la EPH. La agrupación es en 4 categorías (Micro -respuestas 1 al 5, Pequeña – 6 a 8, Mediana 9 y 10, y Grande 11 y 12)

Prompt — Punto 8 (ChatGPT)

"Realice en Python un código que genere una matriz de correlación para 2024T4 y 2025T4 con las siguientes variables: SECTOR, ESTADO, CAT_OCUP, P21, P47T, NIVEL_ED, CH04, CH06, CH07, CH08, utilizando como base un ejemplo con sns.heatmap(df.corr())."

Prompt — Punto 9 (ChatGPT)

"Arma una tabla de estadística descriptiva de todas las variables seleccionadas. La misma debe tener: número de observaciones, promedio, desvío estándar, min, p1, p25, p50, p75, p99 y max, a partir del resumen descriptivo ya generado con describe()."

Bibliografía

Maurizio, Roxana; Monsalvo, Ana Paula (2021). Informality, labour transitions, and the livelihoods of workers in Latin America, WIDER Working Paper, No. 2021/19, ISBN 978-92-9256-953-2, The United Nations University World Institute for Development Economics. Research (UNU-WIDER), Helsinki, <https://doi.org/10.35188/UNU-WIDER/2021/953-2>

Instituto Nacional de Estadística y Censos (INDEC). (2026). Mercado de trabajo. Indicadores de informalidad laboral (EPH). Cuarto trimestre de 2024 a cuarto trimestre de 2025. INDEC,



https://www.indec.gob.ar/uploads/informesdeprensa/informalidad_laboral_eph_04_26798CE_A49F8.pdf

Instituto Nacional de Estadística y Censos (INDEC). (2025). *Encuesta Permanente de Hogares (EPH): Base de microdatos del cuarto trimestre de 2025* [Base de datos]. INDEC. https://www.indec.gob.ar/ftp/cuadros/menusuperior/eph/EPH_registro_4T2025.pdf