



Trabajo Práctico N.º 2

Métodos No Supervisados Usando la EPH

Grupo 5

Santiago Caballero Yver
Oriana Valentina Gegena
Valeria Eliana Gonzalez

Viernes 24 de julio de 2026

Link al repositorio de GitHub:
<https://github.com/santiagocaballeroiver/BigDataUBA-Grupo5>

Parte I: Creación de variables y estadística descriptiva

El presente trabajo continúa con el análisis de la base de ocupados construida en el TP1 que toma como base la EPH (4T2024 y 4T2025), en donde hemos definido el indicador de informalidad (informal_se), según la clasificación de Maurizio & Monsalvo (2021): cuentapropistas del sector informal (CAT_OCUP=2 y SECTOR=2) y trabajadores familiares sin remuneración (CAT_OCUP=4). En esta etapa se crean nuevas variables y se aplican técnicas no supervisadas (PCA y clustering) para explorar si la estructura de los datos logra reflejar la segmentación entre formales e informales.

Creación de variables

Se generaron las nuevas variables para el análisis no supervisado: Se creó la variable edad2 como el cuadrado de la edad (CH06). La variable educ se construyó a partir de tres preguntas de la EPH: el nivel educativo más alto al que asistió la persona (CH12), si llegó a completar ese nivel (CH13) y, en caso de no haberlo completado, el último año o grado que aprobó (CH14). Con esos tres datos se calcularon los años de educación formal, siendo, por ejemplo, una persona que asistió al secundario y lo completó se contabiliza con 12 años de educación formal. Para horastrab se sumaron las horas trabajadas en la ocupación principal y en otras ocupaciones (PP3E_TOT + PP3F_TOT), exclusivamente para el jefe de hogar (CH03 = 1), aplicando un tope de 168 horas semanales (7 días × 24 horas) para corregir errores de carga de la encuesta. Finalmente, nhogar se calculó como la cantidad de miembros por hogar, agrupando por vivienda (CODUSU) y hogar (NRO_HOGAR).

Estadística descriptiva

Se presenta a continuación un resumen estadístico (observaciones, promedio, desvío estándar, mínimo, percentiles 25, 50 y 75, y máximo) de las variables limpias en el TP1 junto con las nuevas variables numéricas para los cuartos trimestres de 2024 y 2025.

Tabla 1. Estadística descriptiva de variables sociodemográficas y laborales – EPH 4T2024

Variable	Obs.	Media	Desvío	Mín.	P25	P50	P75	Máx.
Sexo	37.839	1,53	0,50	1	1	2	2	2
Edad	37.839	43,59	19,01	15	27	42	58	103
Edad ²	37.839	2.261,66	1.831,34	225	729	1.764	3.364	10.609
Años de educación	37.636	11,68	3,84	0	9	12	14	22
Nivel Educativo	37.839	3,91	1,44	1	3	4	5	7
Estado Civil	37.839	3,17	1,65	1	2	3	5	5
Cobertura Médica	37.804	2,07	1,89	1	1	1	4	123
Categoría Ocupacional	22.074	2,70	0,54	1	2	3	3	4
Sector Laboral	20.273	1,38	0,61	1	1	1	2	3
Tamaño de Empresa	18.421	4,99	3,79	0	1	5	8	12
Ingreso principal (P21)	16.329	\$615.856	\$484.813	\$2.000	\$280.000	\$500.000	\$800.000	\$3.000.000
Ingreso total (P47T)	24.510	\$588.928	\$469.695	\$1.000	\$300.000	\$450.000	\$800.000	\$3.000.000
Horas Trabajadas (TP1)	21.082	35,84	16,25	0	25	40	48	118
Horas Trab. Jefe de Hogar	10.375	38,76	16,72	0	30	40	48	123
Miembros del Hogar	37.839	2,91	1,39	1	2	3	4	11

Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025)

Tabla 2. Estadística descriptiva de variables sociodemográficas y laborales – EPH 4T2025

Variable	Obs.	Media	Desvío	Mín.	P25	P50	P75	Máx.
Sexo	35.725	1,53	0,50	1	1	2	2	2
Edad	35.725	44,12	19,24	15	28	42	59	101
Edad ²	35.725	2.316,46	1.869,11	225	784	1.764	3.481	10.201
Años de educación	35.540	11,61	3,88	0	9	12	14	22
Nivel Educativo	35.725	3,89	1,44	1	3	4	5	7
Estado Civil	35.724	3,18	1,65	1	2	3	5	5
Cobertura Médica	35.642	2,08	1,76	1	1	1	4	23

Variable	Obs.	Media	Desvío	Mín.	P25	P50	P75	Máx.
Categoría Ocupacional	20.663	2,68	0,54	1	2	3	3	4
Sector Laboral	18.939	1,39	0,62	1	1	1	2	3
Tamaño de Empresa	16.995	4,80	3,78	0	1	4	8	12
Ingreso principal (P21)	15.290	\$889.117	\$657.502	\$3.000	\$400.000	\$800.000	\$1.200.000	\$4.000.000
Ingreso total (P47T)	22.980	\$838.020	\$648.766	\$700	\$390.000	\$671.400	\$1.095.000	\$4.000.000
Horas Trabajadas (TP1)	19.645	35,91	16,32	0	25	40	48	120
Horas Trab. Jefe de Hogar	9.591	39,07	17,15	0	30	40	48	168
Miembros del Hogar	35.725	2,93	1,39	1	2	3	4	11


Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025)

Al comparar ambos trimestres, las variables sociodemográficas muestran una marcada estabilidad estructural interanual, conservando prácticamente invariables sus medianas de 42 años de edad, 12 años de escolaridad y 3 miembros por hogar. La diferencia más notable entre ambos períodos se observa en el plano nominal, donde el ingreso principal mediano creció de \$500.000 a \$800.000 como reflejo directo del proceso inflacionario. En cuanto al esfuerzo laboral de los jefes de hogar, las medidas centrales se mantuvieron estables en torno a las 40 horas semanales; cabe destacar que se aplicó un tope de 168 horas semanales a las observaciones que reportaban valores superiores, garantizando la consistencia física de los datos.

Matriz de correlaciones

Con la base de ocupados de cada año se construyó una matriz de correlación entre la informalidad (informal_se) y los predictores sociolaborales del TP1 y del presente TP: edad, edad2, educ, horastrab, nhogar, P21 y PP04C, con el fin de identificar qué variables muestran mayor asociación lineal con la informalidad antes de aplicar las técnicas no supervisadas.

Gráfico 1. Matriz de correlación entre informalidad y predictores sociolaborales, EPH 2024 y 2025



Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025)

El análisis de las matrices de correlación para 2024 y 2025 revela una persistencia importante en los determinantes estructurales de la informalidad laboral. Comparando las matrices de correlación de 2024 y 2025 se puede observar que los factores que influyen en la informalidad son prácticamente los mismos. La informalidad tiende a ser menor cuanto más grande es la empresa (PP04C), cuanto mayor es el ingreso principal (P21) y cuantos más años de educación formal tiene la persona, aunque estas relaciones son de intensidad baja a moderada. Como análisis de esto podemos decir que la precariedad laboral aparece más entre trabajadores con menos nivel educativo y en unidades productivas más chicas. Que las correlaciones sean bajas también tiene su lectura: significa que la informalidad no se explica por una sola causa, sino que responde a varios factores combinados. Y el hecho de que los coeficientes prácticamente no se muevan entre un año y otro sugiere que el mercado de trabajo argentino tiene una estructura bastante rígida, que no reacciona demasiado a los cambios macroeconómicos de corto plazo.

Parte II: Métodos No Supervisados


A diferencia de la matriz de correlaciones, que solo capta asociaciones lineales bivariadas, los métodos no supervisados exploran la estructura conjunta de los datos sin necesidad de conocer con anticipación la variable de

interés: PCA resume la variabilidad en un número menor de componentes ortogonales, y el clustering (k-medias, jerárquico y k-modas) agrupa directamente a las observaciones según su similitud.

A. Análisis de Componentes Principales (PCA)

Se aplicó PCA sobre edad, edad2, educ, horastrab, nhogar, P21 y PP04C, previa estandarización (media 0, desvío 1) para que las diferencias de escala entre variables no distorsionen el peso de cada una en los componentes.


Gráfico 2. Scores del primer y segundo componente principal, por condición de informalidad



Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025)

En ambos años el modelo captura ~56% de la varianza total (33,5% PC1, 23% PC2). Los informales se concentran en el cuadrante inferior derecho (PC1 positivo, PC2 negativo), mientras que los formales dominan el espectro izquierdo y superior, sugiriendo un eje latente de precariedad. Se identifican outliers en ambos períodos (scores de hasta ~4 en vertical y ~6 en horizontal), con un patrón estable entre 2024 y 2025.


Gráfico 3. Biplot de PCA: scores y loadings de las variables, por condición de informalidad



Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025)

El biplot muestra un patrón de segmentación diagonal consistente entre 2024 y 2025: los formales convergen hacia el cuadrante superior izquierdo, alineados con los vectores de P21, educación y tamaño del establecimiento (PP04C); los informales se agrupan en el cuadrante opuesto, con un desplazamiento adicional asociado a edad y tamaño del hogar. Esto confirma que la informalidad se define por un nivel educacional más bajo y escala productiva, con un perfil demográfico distintivo estable entre años.

Gráfico 4. Proporción de varianza explicada por componente principal




Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025)

El primer componente es el más relevante en ambos años (33,5% en 2024, 33,3% en 2025); el segundo aporta ~23%. Los componentes 3 a 6 aportan de forma decreciente (15% a 7%) y el séptimo es insignificante (0,2%). Con PC1+PC2 se retiene más del 56% de la varianza, y con 3 componentes se llega a ~72%. La estructura es estable entre 2024 y 2025, en línea con lo observado en la matriz de correlaciones.

B. Clúster


El clustering agrupa directamente a las observaciones según su similitud. Se aplicaron tres algoritmos: k-medias (particiona en k grupos minimizando la varianza intra-grupo, $k=2$ y $n_{init}=20$), jerárquico (no requiere fijar k de antemano) y k-modas (pensado para variables categóricas).

Gráfico 5. Clusters K-medias ($k=2$) vs. condición real de informalidad – EPH 2024 y 2025



Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025)


Gráfico 6. Método del codo para k-medias ($k=1$ a 40)



Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025)

El algoritmo con $k=2$ no logra separar con precisión a informales y formales: aunque los informales tienden a concentrarse en menores ingresos (P21) y menos horas trabajadas, hay gran superposición y no se observa una frontera clara. El gráfico del codo muestra una caída abrupta entre $k=1$ y $k=4$, que se suaviza desde $k=5$; el número óptimo de clusters se ubica entre 3 y 5 ($k=4$ como referencia).

Gráfico 7. Dendrograma de clustering jerárquico, método Ward – EPH 2024 y 2025



Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025)


Un dendrograma representa en forma de árbol el proceso de agrupamiento jerárquico: cada fusión indica a qué distancia se unen dos observaciones o grupos. Con un corte sugerido en $y=35$ se identifican $k=3$ clusters óptimos en ambos años (ramas naranja, verde y roja); forzar $k=2$ uniría perfiles heterogéneos. La formación de grupos es muy similar entre 2024 y 2025, lo que confirma la estabilidad de la estructura laboral de la EPH. Esto complementa

el método del codo: 3 grupos (bajos ingresos/baja calificación, ingresos medios/informales, y formales de alta calificación) reflejan mejor la heterogeneidad del mercado que la partición binaria de $k=2$.

Clúster k -modas

A diferencia de k -medias y del clustering jerárquico, que trabajan con distancias euclídeas, k -modas agrupa a los individuos según la coincidencia de sus atributos categóricos (nivel educativo, tipo de actividad, etc.), lo cual resulta pertinente dado que buena parte de las variables de la EPH son categóricas. Al realizar este análisis observamos que los resultados coinciden con lo encontrado en los puntos anteriores, la estructura socio-laboral de la EPH se concentra en 3 o 4 segmentos diferenciados.

Gráfico 8. Método del Codo (k -moda) – EPH 2024 y 2025



Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025)

En ambos años el codo más claro aparece entre $k=3$ y $k=5$, con el quiebre más marcado en $k=4$. Hasta 4 la caída del costo de disimilitud es empinada, luego sigue bajando, pero mucho más lento y con rendimientos marginales decrecientes, vemos que es consistente entre los dos períodos. Comparándolo con k -medias se distingue que para este caso las curvas son mas ruidosas o menos monótonas, en 2024 el costo cae aproximadamente un 15% solo pasando de 1 a 2 clústeres, y sigue cayendo fuerte hasta $k=4$, al tener solo 4 variables categóricas, dividir en 2 grupos ya captura una porción grande de la estructura. En el k -medias continuo, al tener 7 variables numéricas con relaciones más graduales (edad, ingreso, etc.), la caída del codo era más progresiva y no tan concentrada en los primeros k .

Parte III: Herramientas de IA y reflexión final

Para este trabajo la IA nos ayudo no solo a agilizar el armado del código sino también con la interpretación de los gráficos a profundidad y notando determinadas funciones que se nos habían pasado en una primera revisión. Fue muy útil para ordenar paso a paso el código, especialmente en la parte II ya que nos tomaba mucho tiempo determinar que subset usar entre todos los que ya habíamos filtrado y en la corrección de errores que iban apareciendo mientras corríamos el código completo.

Apéndice

A continuación, se listan, en el orden en que fueron utilizados, los prompts de inteligencia artificial empleados a lo largo del trabajo práctico, junto con la LLM utilizada en cada caso.

Prompt 1 – ChatGPT

Tengo este codigo (código) y me sale este error en la parte de componentes principales (parte ii) File <string>:9 scaler = StandardScaler() ^IndentationError: unindent does not match outer indentation level

Prompt 2 – ChatGPT

Necesito mayor interpretación para el siguiente gráfico (Dendrograma) para el eje vertical.

Prompt 3 – ChatGPT

quiero hacer como en esta parte (código TP1) que no usa una variable para cada año sino que todo lo mismo hasta que al final separa por año para graficar. (Para K-medias)

Prompt 4 – ChatGPT



*Tengo el siguiente error: Cell In[41], line 5 f graficar_dendrograma(df_ocupados, anio, n_muestra=1000):
^SyntaxError: invalid syntax*

Prompt 5 – Chat GPT

¿Para el siguiente gráfico está bien asumir que el número de clúster optimo es 4? (Foto del gráfico de codo para k-modas)