



Trabajo Práctico N.º 3

Clasificando Informales en la EPH

Grupo 5

Santiago Caballero Yver
Oriana Valentina Gegena
Valeria Eliana Gonzalez

Lunes 17 de Agosto de 2026

Link al repositorio de GitHub:
<https://github.com/santiagocaballeroyver/BigDataUBA-Grupo5>



A. Enfoque de validación: 2024 como entrenamiento, 2025 como testeo

1. Matrices X, vectores y, y base MM

A partir de la base ocupados construida en el TP1 y TP2, se separaron las observaciones de 2024 (entrenamiento) y 2025 (testeo), cada una con su matriz de características X y su vector y de informalidad según la definición asignada al grupo (cuentapropistas informales, CAT_OCUP=2 con SECTOR=2, y trabajadores familiares sin remuneración, CAT_OCUP=4). Para extender el enfoque de Maurizio & Monsalvo (2021) se construyó adicionalmente la base ocupados_X_2025_MM, que incorpora el estatus de informalidad de 2024 (informal_se_2024) para la misma persona mediante una unión por intersección (inner join) sobre CODUSU, NRO_HOGAR y COMPONENTE. Luego de esta unión se eliminaron las columnas de identificación, ya que no son características relevantes para predecir informalidad.

2. Tabla de diferencias de medias 2024 vs. 2025

Variable	Media 2024	Media 2025	Dif. (25-24)	t-stat	p-value	Signif.
Edad	41.31	41.87	0.56	4.31	0.00	***
edad2	1878.81	1929.49	50.68	4.38	0.00	***
Educ	12.48	12.41	-0.07	-1.91	0.06	*
Horastrab	38.76	39.07	0.30	1.27	0.20	
P21_miles	809.85	889.12	79.27	10.87	0.00	***
Nhogar	2.85	2.86	0.01	1.02	0.31	
Género	0.45	0.45	0.00	0.95	0.34	
Cobertura	0.71	0.70	-0.01	-2.28	0.02	**

Tabla 1. Diferencia de medias entre ocupados_X_2024 y ocupados_X_2025 (*** $p < 0.01$, ** $p < 0.05$, * $p < 0.10$). χ^2 tam_empresa: 22.45, $p < 0.001$.

Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025).

Hay diferencias grandes y significativas: P21_miles (+79,27 miles de pesos ajustados por inflación) implica un salto de aproximadamente 9,8% en el ingreso principal entre 2024T4 y 2025T4, y es la diferencia más relevante tanto en términos estadísticos ($p < 0,01$) como económicos. La distribución de tam_empresa entre micro y no-micro también cambió de forma significativa entre años ($\chi^2 = 22,45$, $p < 0,001$).

También se observan diferencias estadísticamente significativas, pero económicamente chicas: edad (+0,56 años) y edad2, significativas al 1% pero que reflejan un envejecimiento poblacional casi trivial, y Cobertura (-0,01, $p = 0,02$), una caída mínima en cobertura de salud (70,7% $\rightarrow$ 70%). En cambio, horastrab, nhogar y Género no muestran diferencias significativas entre 2024 y 2025, en línea con la estabilidad estructural interanual de las variables sociodemográficas ya observada en el TP2.

B. Modelo de Regresión Logística: extensión de Maurizio & Monsalvo (2021)

1. Estimación y efectos marginales

Se estimaron dos modelos de Regresión Logística para predecir la probabilidad de informalidad: el modelo 2024 (base, sobre ocupados_X_2024) y el modelo 2025_MM, que sigue la especificación de Maurizio & Monsalvo (2021) incorporando el lag informal_se_2024. En ambos casos la variable tam_empresa se recodificó como dummy binaria (tam_micro vs. tam_no_micro), tras diagnosticar que el modelo original con 4 categorías no convergía por cuasi-separación: la informalidad está concentrada casi por completo en tam_micro ($\approx 42\%$ de tasa de informalidad en 2024), mientras que las demás categorías tienen tasas casi nulas y muy pocas observaciones informales.

Modelo 2024 (base):

Variable	Coef.	E.E.	Odds Ratio	p-value
Const	1.20	0.47	3.32	0.01
Edad	-0.03	0.02	0.97	0.19



Variable	Coef.	E.E.	Odds Ratio	p-value
edad2	0.00	0.00	1.00	0.01
Educ	-0.00	0.01	1.00	0.93
Horastrab	-0.00	0.00	1.00	0.08
P21_miles	-0.00	0.00	1.00	0.00
Nhogar	-0.05	0.03	0.95	0.14
Género	-0.82	0.09	0.44	0.00
Cobertura	-1.39	0.09	0.25	0.00
tam_empresa_no_micro	-5.77	0.71	0.00	0.00

Tabla 2a. Coeficientes, error estándar, odds ratio y p-value — Modelo 2024.

Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025).

Modelo 2025 (con lag de informalidad, especificación Maurizio & Monsalvo):

Variable	Coef.	E.E.	Odds Ratio	p-value
Const	2.52	1.01	12.49	0.01
Edad	-0.10	0.04	0.91	0.02
edad2	0.00	0.00	1.00	0.01
Educ	-0.03	0.02	0.97	0.26
Horastrab	-0.01	0.00	0.99	0.07
P21_miles	-0.00	0.00	1.00	0.00
Nhogar	0.01	0.07	1.01	0.83
Género	-0.87	0.17	0.42	0.00
Cobertura	-1.20	0.17	0.30	0.00
informal_se_2024	2.60	0.16	13.52	0.00
tam_empresa_no_micro	-5.15	1.01	0.01	0.00

Tabla 2b. Coeficientes, error estándar, odds ratio y p-value — Modelo 2025_MM.

Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025).

Los dos modelos convergen sin problemas de separación luego de recodificar tam_empresa. tam_empresa_no_micro es el predictor dominante en ambos (coef=-5,77 en 2024 y -5,15 en 2025_MM, $p<0,001$): operar fuera de una microempresa reduce las chances de ser cuentapropista informal en más del 99% ($OR\approx 0,003-0,006$), lo que confirma el diagnóstico del crosstab y explica por qué educ pierde toda significatividad en ambos modelos completos ($p=0,93$ en 2024, $p=0,26$ en 2025_MM), ya que su efecto queda absorbido por tam_empresa.

El género es un predictor robusto y estable una vez controlado por tamaño de empresa (coef $\approx -0,82/-0,87$, $p<0,001$ en ambos años): ser mujer reduce las chances de informalidad en cuentapropismo en aproximadamente 55-58% ($OR\approx 0,42-0,44$). informal_se_2024 es el predictor más fuerte del modelo con lag: haber sido informal en 2024 multiplica por 13,5 las chances de serlo en 2025, controlando por el resto de las características — evidencia robusta de dependencia de estado. P21_miles y Cobertura se mantienen significativas y con el signo esperado en ambos modelos. La edad cambia de forma llamativa entre años: no significativa en 2024 ($p=0,19$) pero sí en 2025_MM ($p=0,02$), ganando peso una vez controlado simultáneamente por tam_empresa y el lag de informalidad. El pseudo- R^2 salta de 0,388 (2024) a 0,544 (2025_MM), en gran parte por la inclusión de informal_se_2024.

2. Visualización: probabilidad predicha vs. edad, por nivel de educación

Para aislar el efecto de la educación —opacado por tam_empresa en el modelo completo, dado que para un cuentapropista el tamaño de establecimiento reportado es casi tautológico con la propia definición de informalidad— se estimó un modelo reducido (modelo_2024_sin_tam), usado únicamente para esta visualización y no para la tabla de coeficientes ni para la evaluación de desempeño. Siguiendo el estilo de Horowitz & Savin (2001), se fijó un perfil de trabajador en riesgo (sin cobertura de salud, ingreso en el percentil 10) y se graficó la probabilidad predicha en función de la edad para dos niveles de educación (12 años = secundario completo, 17 años = universitario completo).




Gráfico 1. Probabilidad predicha de informalidad según edad, por nivel de educación (modelo reducido sin tam_empresa, perfil de riesgo).

Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025).

Al sacar tam_empresa de la especificación, el coeficiente de educ crece en magnitud (de -0,0009 a -0,0124, ~13x), consistente con que parte del efecto de la educación estaba siendo absorbido por el tamaño de empresa; sin embargo, sigue sin ser significativa ($p=0,24$). P21_miles ($p<0,001$) y Cobertura ($p<0,001$) ya capturan buena parte de la información que la educación aportaría, funcionando como proxies más directas de la formalidad. La curva muestra una forma en S marcada: la probabilidad predicha sube de forma pronunciada entre los 40 y los 75 años (de ~0,40 a ~0,90), un efecto dominado por edad y edad2 más que por educación. La brecha entre educ=12 y educ=17 es visible pero chica (menos de 2 p.p. en cualquier punto de la curva), consistente con la falta de significatividad de educ.

C. Desempeño del modelo y predicción afuera de la muestra

1. Matriz de confusión, curva ROC y métricas




Gráfico 2. Matrices de confusión (umbral $p>0,5$) — Modelo 2024 (fuera de muestra) vs. Modelo 2025_MM (in-sample).

Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025).




Gráfico 3. Curva ROC del modelo logit (2024 vs. 2025_MM).

Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025).

Modelo	Accuracy	Sensibilidad	VPP (Precision)	Especificidad	AUC-ROC
2024 (fuera de muestra)	0.88	0.34	0.72	0.98	0.92
2025_MM (con lag)	0.92	0.65	0.77	0.97	0.95

Tabla 3. Métricas de desempeño (umbral $p > 0,5$).

Fuente: Elaboración propia en base a EPH (4T2024 y 4T2025).

En la diagonal principal de la matriz de confusión están los aciertos (verdaderos negativos arriba-izquierda, verdaderos positivos abajo-derecha) y fuera de la diagonal los errores tipo I (falsos positivos) y tipo II (falsos negativos). En la curva ROC, cuanto más se acerca cada curva a la esquina superior izquierda, mejor clasifica el modelo; la diagonal es el clasificador aleatorio (AUC=0,5). Ambos modelos muestran alta especificidad (98% y 97%), identificando muy bien a los trabajadores formales. La diferencia relevante está en la sensibilidad: el modelo 2024 detecta solo el 34% de los informales reales (152 de 441, con 289 falsos negativos), mientras que el modelo 2025_MM casi duplica esa detección (65%, 285 de 441). Esta caída de sensibilidad en el modelo 2024 es esperable dado que `tam_empresa_no_micro` domina el modelo con un coeficiente muy negativo: tiende a clasificar como "Formal" a cualquiera que no esté en una microempresa, ganando especificidad a costa de sensibilidad.

La curva ROC confirma que el modelo 2025_MM domina en todo el rango de umbrales (AUC=0,953 vs. 0,916), con la brecha más marcada en la zona de tasas de falsos positivos bajas (0-0,2). En las cinco métricas el modelo 2025_MM domina al modelo 2024: mejor precisión (92% vs. 88%), mejor sensibilidad (65% vs. 34%, la mejora más grande), mejor VPP (77% vs. 72%) y mejor AUC (0,95 vs. 0,92), con especificidad apenas un punto menor (97% vs. 98%). Esto es consistente con el peso del predictor `informal_se_2024` (OR≈13,5). Cabe aclarar que el modelo 2025_MM está evaluado in-sample, mientras que el modelo 2024 es genuinamente fuera de muestra, por lo que parte de esta ventaja probablemente se achicaría si el modelo 2025_MM se evaluara también en un conjunto de test separado.

2. ¿Qué modelo es "mejor" para la Secretaría de Trabajo?

El modelo 2025_MM tiene AUC y precisión mucho más altas, casi enteramente por el peso de `informal_se_2024` (OR≈8-9 en efectos marginales). Sin embargo, esto plantea un problema conceptual para el caso de uso: si el modelo predice "informal en 2025" principalmente porque la persona ya era informal en 2024, no está agregando información nueva para la política pública, solo confirma algo que un funcionario ya



podría inferir mirando el registro del año anterior. Es útil para persistencia, pero tiene poco valor para identificar nuevos entrantes a la informalidad o anticipar el fenómeno en personas sin historial observado.

El modelo 2024 (sin lag) identifica el perfil estructural asociado a informalidad (baja educación, changas de pocas horas, empresas chicas, sin cobertura de salud), lo que sirve para targetear con base en características observables sin necesitar el historial de la persona — más realista si la Secretaría no cuenta con un panel individual actualizado (la EPH es una muestra, no un censo). Para la asignación de recursos escasos importa más la precisión que el recall: cada persona mal clasificada como informal (falso positivo) es un recurso del programa mal asignado. En ese caso conviene mirar la columna Precision de la Tabla 3 y no solo el AUC, y eventualmente mover el umbral de 0,5 hacia arriba si el objetivo es maximizar la eficiencia del gasto por sobre la cobertura.

D. Herramientas de IA y reflexión final

Para este trabajo el uso de la IA fue fundamental para guiar el proceso de selección de variables, ya que al principio nos encontramos con muchas trabas respecto a la variable `tam_empresa` que nos opacaba todo el análisis y, además, el logit no tiene manera de identificar por separado el efecto de cada dummy de tamaño. En este sentido, le compartimos el código para que detecte el problema principal. En este trabajo en particular, no fue muy útil como guía para las interpretaciones de los gráficos y tablas, ya que los cambios realizados en el medio eran difíciles de seguir.

Apéndice: prompts de IA utilizados (Claude)

- A partir de esta base, tengo que predecir si una persona es informal o no (cuentapropista informal) a partir de la base ocupados. En la tabla de diferencias de medias quiero separar significativo estadísticamente de relevante económicamente sin sobre interpretar.
- En el modelo 2 mi base de ocupados_X_2025_MM pierde el índice original y me tira error (adjunte foto) cuando agrego `y_2025`. Cómo lo ajusto?
- La tabla me tira errores estandar muy altos. Serviría eliminar la variable P21?
- El gráfico queda aplastado incluso modificando P21 a miles (foto)
- El modelo no converge y tengo el siguiente error: Warning: Maximum number of iterations has been exceeded. ... converged: False ... Possibly complete quasi-separation: A fraction 0.19 of observations can be perfectly predicted. This might indicate that there is complete quasi-separation. In this case some parameters will not be identified. -- Que está tomando mal?
- Si Prácticamente el 100% de los cuentapropistas informales de la muestra son de empresas micro, cómo podría modificarlo para agregar la dummy que divida entre trabaja en empresa micro vs no trabaja?
- Como y donde transpongo la matriz de confusion?
- Para el gráfico de edad/educación quiero sacar la variable de tamaño de empresa para que se vea el efecto mas limpio, es posible? (foto del gráfico)

Tiempo total dedicado

El tiempo total que nos llevó este trabajo fue de aproximadamente 8 horas.

Referencias

Maurizio, Roxana; Monsalvo, Ana Paula (2021). *Informality, labour transitions, and the livelihoods of workers in Latin America*. WIDER Working Paper, No. 2021/19, ISBN 978-92-9256-953-2, The United Nations University World Institute for Development Economics Research (UNU-WIDER), Helsinki. <https://doi.org/10.35188/UNU-WIDER/2021/953-2>